딥러닝 프로젝트 계획

# 스펙트로그램 기반 베어링 고장진단

운전 조건이 바뀌어도 흔들리지 않는 진단을 목표로

[이름] · [학번] · 2026.11.03

# 목차


01 주제 선정 이유

02 데이터 소개

03 기존 방법: 1D CNN

04 제안: 2D CNN

05 실험 계획

06 일정

01 주제 선정 이유

# 설비가 멈추기 전에, 초기 결함을 진동으로 찾기

## 문제

베어링은 모터, 펌프 같은 회전 설비의 핵심 부품. 갑자기 고장 나면 설비 전체가 멈춘다

## 해결 방향

작은 결함만 생겨도 진동 패턴이 달라진다. 결함이 커지기 전에 찾아 정비한다 (예지정비)

## 현장의 어려움

실험실과 달리 현장은 운전 조건이 계속 바뀌고 잡음도 섞인다. 조건이 바뀌어도 맞히는 강건한 모델이 필요하다

02 데이터 소개

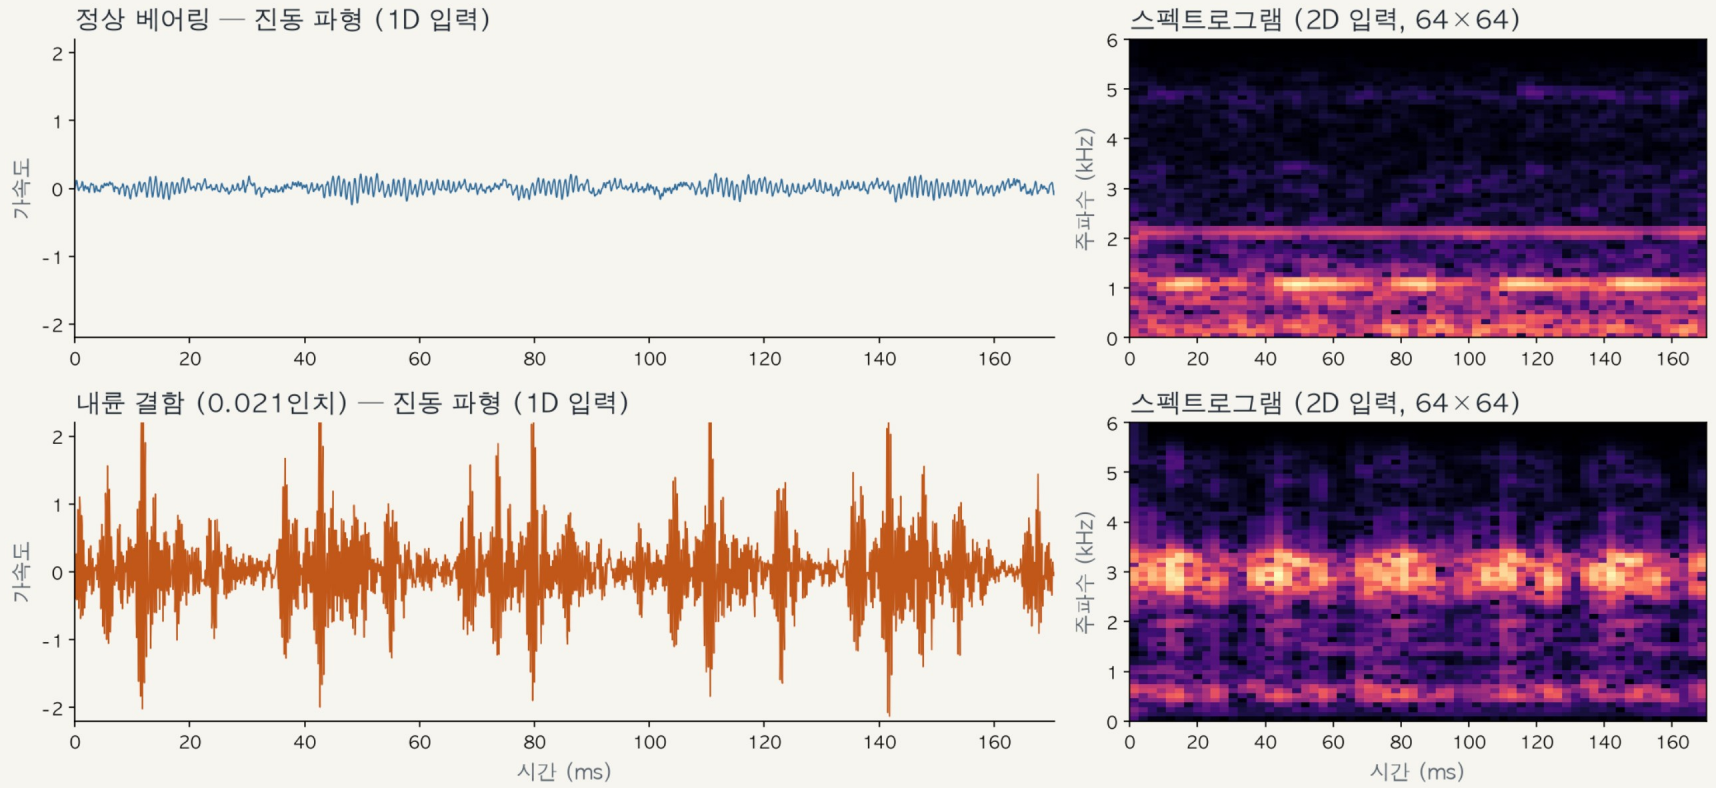
# CWRU 데이터: 결함이 생기면 진동에 무늬가 생긴다

10개 클래스: 정상 + 결함 9종

결함 위치 3곳 × 크기 3단계

운전 조건(부하) 0~3마력

입력 1개 = 0.17초 (2048점)



03 기존 방법: 1D CNN

# WDCNN: 진동 파형을 그대로 보는 1D CNN

원신호 파형
2048점

→

넓은 첫 합성곱
(커널 64)

→

합성곱 4층
+ 풀링

→

10개 클래스
판정

### 장점

전처리 없이 원신호를 바로 학습. 구조가 단순하고 가볍다

### 의문점

결함 정보는 주파수에 담겨 있는데, 모델이 파형에서 그걸 스스로 찾아야 한다. 조건이 바뀌어도 잘 찾을까?

04 제안: 2D CNN

# 신호를 그림으로 바꿔서 2D CNN으로

원신호 파형
2048점

→

STFT
(짧은 구간 FFT)

→

스펙트로그램
64×64

→

2D CNN
→ 10개 클래스

## 왜 스펙트로그램인가

결함은 특정 주파수 대역의 반복 무늬로 드러난다. 주파수 정보를 그림으로 직접 보여주면 조건이 바뀌어도 무늬를 잘 잡을 것이다 (가설)

## 왜 RNN이 아니라 CNN인가

결함 무늬는 구간 어디에서나 나타나는 국소적인 반복 패턴. CNN은 같은 필터로 위치와 상관없이 잡는다. RNN(LSTM)은 대조군으로 함께 비교

05 실험 계획

# 같은 조건에서 공정하게 비교한다

| 항목 | 내용 |
| --- | --- |
| 비교 모델 | 1D CNN (기존 WDCNN) · 2D CNN (제안) · LSTM (대조군) |
| 평가 조건 | 깨끗한 데이터 · 운전 조건(부하) 변화 · 잡음 추가 |
| 공정성 | 같은 학습 설정 · 3회 반복 평균 · 데이터 누수 방지 분할 |
| 평가 지표 | 정확도 · F1 점수 · 혼동 행렬 · 모델 크기와 연산량 |
| 이후 개선 | 결과를 보고 손실함수 · 최적화 · 활성화 · 전처리 개선 |

06 일정

# 주차별 계획

| | |
|---|---|
| **11/3 주** | 계획 발표 · 데이터 준비 |
| **11/10 주** | 1D CNN · 2D CNN · LSTM 구현과 비교 실험 |
| **11/17 주** | 결과 분석 · 개선 방향 결정 |
| **11/24 주** | 개선 실험: 손실함수 · 최적화 · 활성화 · 전처리 |
| **[최종 주]** | 결과 보고서 · 최종 발표 |